Além da Inspeção Visual: Detecção de Insetos-Praga com Aprendizado Profundo

Gabriela S. C. Ponciano [1], Bianca S. Soares[1], Sara S. Magalhães[1], Deborah M. V. Magalhães[2], Atslands R. Rocha[1]

[1]Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará (UFC)

[2]Universidade da Integração Internacional da Lusofonia Afro-Brasileira (Unilab – CE)

{gabriela.ponciano, biancasoares, saradesousa}@alu.ufc.br

deborah.vm@unilab.edu.br, atslands@ufc.br

Abstract. *Agricultural pests are a major cause of crop losses worldwide and significantly affect agricultural productivity. Advances in Computer Vision and Machine Learning have enabled automated pest detection methods that reduce human intervention, minimize errors, and provide faster analysis. In this context, this study proposes the use of a lightweight model, YOLO12n, trained on a dataset comprising 9427 images for monitoring five species of insect pests. The model achieved an mAP@0.5 of 0.9836, an mAP@0.5:0.95 of 0.8663, a precision of 0.9456, and a Recall of 0.9686. These results demonstrate the effectiveness and robustness of the proposed model for the detection of agricultural pests, highlighting its potential for automated field monitoring.*

Resumo. *As pragas agrícolas são uma das principais responsáveis pela diminuição de safras anualmente. Com o avanço da Visão Computacional e do Aprendizado de Máquina, foram desenvolvidas maneiras automatizadas de controle de pragas, sendo menos suscetíveis a erros, mais rápidas e exigindo menos esforço de mão de obra. Tendo isso em vista, a proposta desse trabalho é a aplicação de um modelo leve, o YOLO12n, para monitoramento de cinco espécies de insetos-praga, utilizando uma base de dados com 9427 imagens. Os resultados obtidos por esse modelo foram mAP@0,5 de 0,9836, mAP@0,5:0,95 de 0,8663, Precisão de 0,9456 e Recall de 0,9686. Assim, esses valores indicam resultados robustos na detecção de pragas agrícolas, destacando a viabilidade do modelo para o monitoramento automatizado em campo.*

1. Introdução

A agricultura é uma prática de suma importância para a sociedade, especialmente para o setor econômico e para a produção de alimentos. No Brasil, ela é um dos setores que mais contribuem para o aumento do Produto Interno Bruto (PIB) [Embrapa 2020]. Apesar disso, a agricultura ainda sofre com a problemática da infestação de pragas, responsável por perdas econômicas que diminuem a qualidade da produção agrícola [Lee et al. 2026]. Além disso, estima-se que as doenças e pragas agrícolas são causadoras de cerca de 20% a 40% de redução das safras globais anualmente, contribuindo, também, para o aumento da insegurança alimentar [FAO 2026]. Assim, é imprescindível um melhor controle de pragas agrícolas.

O controle de pragas agrícolas baseia-se em abordagens para combater a infestação de insetos-praga no campo de agricultura, diminuindo o impacto negativo causado por eles. Existem variadas formas de controle, sendo uma das mais comuns o denominado controle alternativo, o qual possibilita a utilização de armadilhas contendo soluções atrativas [Embrapa 2005]. Contudo, o uso de armadilhas para detecção manual de pragas é mais suscetível a erros humanos, há uma maior necessidade de tempo e pode exigir um maior esforço de mão de obra.

Nesse contexto, técnicas automatizadas de controle auxiliam em uma tomada de decisão mais rápida e são menos suscetíveis a erros. Os recentes avanços na área da tecnologia, especialmente em Visão Computacional atrelada ao Aprendizado de Máquina, mostram soluções eficientes para automatização no processo de detecção de pragas agrícolas. Além disso, outro importante avanço foi na integração entre Aprendizado de Máquina e IoT (*Internet of Things*), que possibilitou a utilização de modelos em dispositivos embarcados, podendo diminuir a latência e o uso de largura de banda [Raj et al. 2026]. Essa abordagem é demonstrada no trabalho de [Soares et al. 2024], o qual investiga a utilização de modelos para a identificação do inseto-praga *Spodoptera frugiperda* e a implementação em um *Raspberry Pi*.

Apesar disso, os modelos de detecção possuem desafios pertinentes para manter resultados confiáveis quando implementados em dispositivos IoT, que, muitas vezes, possuem recursos computacionais limitados [Raj et al. 2026]. Tendo isso em vista, este trabalho propõe o uso do modelo de detecção YOLO12 [1], especificamente na versão nano, para o monitoramento de cinco espécies de pragas agrícolas, com a utilização de uma base de dados pública obtida na plataforma Roboflow[2], representando uma análise experimental da contribuição para o controle de inseto-praga, do grupo das mariposas, em campos de agricultura.

2. Trabalhos Relacionados

Esta sessão tem como objetivo discutir os principais trabalhos relacionados presentes na literatura. São considerados cinco enfoques diferentes: objetivo, modelo utilizado, métricas de avaliação, resultados e conjunto de dados. A Tabela 1 sintetiza as comparações realizadas.

Em [Zhao et al. 2026], é proposto um modelo leve, baseado no YOLO8n, cujo objetivo é a detecção de pragas, aumentando a acurácia e mantendo-o ideal para *deployment* em dispositivos na borda em campos de algodão. O modelo apresentado utiliza SimAM, um módulo de atenção sem parâmetros que limita a interferência do fundo, e inclui P2, uma cabeça de atenção que, juntamente com DySample, restaura detalhes espaciais de alta resolução. O conjunto de dados utilizado foi elaborado no próprio trabalho e consiste em 4.236 imagens, com 4 classes distintas de pragas de algodão. O modelo proposto por essa pesquisa alcançou Precisão de 91,1%, *Recall* de 87,4% e mAP@0.5 de 90,5%. Além disso, obteve o menor número de parâmetros, 2,80 milhões, em comparação com outros modelos, como o modelo base YOLO8n, que possui 3,01 milhões de parâmetros.

No trabalho de [Arunachalam et al. 2026] é desenvolvido um modelo de detecção de pragas aprimorado baseado em IoT. O modelo implementado para detecção nessa

[1]https://docs.ultralytics.com/pt/models/yolo12

[2]https://universe.roboflow.com/

pesquisa constitui-se da funcionalidade do modelo YOLOv5 com a aptidão de detecção avançada do TransUnet, denominado YOLOv5-TUnet. Para a classificação foi utilizado o modelo Adaptive MobileNet em conjunto com IFLO. Nesse estudo foi utilizado o conjunto de dados *"IP102-Dataset"*, o qual contém 75.222 imagens com 102 classes de pragas. O modelo YOLOv5-TUnet obteve como resultado Coeficiente de Dice de 94,9%, Coeficiente de Jaccard de 90,3% e acurácia de 94,9%

[Vedula and Arunachalam 2026] apresenta o desenvolvimento de um sistema constituído por sensores espalhados em campo e uma Rede Neural Convolucional (CNN) para a detecção precoce de pragas em cultivo de arroz. A base de dados é formada por 20.000 imagens contendo 5 classes distintas, incluindo pragas da cultura de arroz e folhas saudáveis. O resultado desse sistema mostra uma acurácia de 92,8%, *Recall* de 91,2% e *f1-score* de 92,0%, além de um atraso 45 vezes menor se comparado com o monitoramento manual.

No estudo de [Xue et al. 2025] é apresentado um sistema em tempo real e de alta precisão de detecção de pragas, que integra os modelos ResNet-50, *Vision Transformer* (ViT) e uma CNN personalizada em um ecossistema IoT. Foi utilizada a *Agricultural Pest Image Dataset*, obtida da plataforma Kaggle, como base de dados, a qual consiste em 5.494 imagens rotuladas em 12 classes de pragas agrícolas. O modelo proposto obteve uma acurácia de 97,09%.

[Barhate et al. 2025] propõe o AgriShield, um sistema de detecção de pragas agrícolas indianas em tempo real, que utiliza o modelo YOLO11, denominado Pest-YOLOv11, e integra-se ao ESP32-CAM e a um sensor PIR. Para a base de dados, foi utilizado o *Pestopia dataset*, originado da plataforma Kaggle, o qual contém cerca de 19.000 imagens e 60 categorias de pragas. Além disso, as imagens foram rotuladas utilizando a plataforma Roboflow. O modelo alcançou mAP de 85%, Precisão de 88% e *Recall* de 82%, além de ter menos parâmetros do que modelos anteriores, como YOLO8 e YOLO5.

Em [Hakim et al. 2026] é demonstrada a avaliação de modelos presentes no estado da arte para detecção de múltiplas pragas agrícolas pequenas. Os modelos utilizados foram o YOLO, das versões 7 a 13. Foi utilizado o *Five-Pest* como conjunto de dados, constituído por 17.251 imagens capturadas por armadilhas inteligentes e possui 5 classes de pragas distintas, rotuladas usando a plataforma Roboflow. Foram obtidos resultados das 7 versões do modelo YOLO, em que YOLO9 obteve o maior resultado para mAP@50, alcançando resultado de 92,9%, Precisão de 88% e Recall de 87,4%. Porém, realizou o treino com atraso de 8 horas em relação à versão 8, que obteve um mAP@50 de 92,4%, o segundo maior valor para essa métrica.

De modo geral, os trabalhos citados anteriormente apresentam resultados relevantes quanto à aplicação de modelos de Aprendizado de Máquina para a detecção automatizada de pragas agrícolas. Contudo, este trabalho possui diferenças relevantes quanto às demais pesquisas, sobretudo no que se refere à base de dados, em que foram utilizadas imagens específicas de um grupo de pragas, as mariposas. Além disso, diferentemente dos outros trabalhos, esta pesquisa focou na utilização do modelo YOLO12n, uma versão mais recente e mais leve, relevante para cenários agrícolas, diferentemente da pesquisa de [Hakim et al. 2026], na qual foi testada a versão 13, mas não a versão nano, evidenciando

a diferença na versão de modelos leves.

Tabela 1. Trabalhos Relacionados

Trabalho	Objetivo	Modelo	Métricas	Conjunto de dados
[Zhao et al. 2026]	Detecção de pragas de algodão	YOLO8n	Precisão 91,1% *Recall* 87,4% mAP@0.5 90,5% Parâmetros 2,80M	4.263 imagens de pragas de algodão com 4 categorias
[Arunachalam et al. 2026]	Detecção de pragas baseado em IoT	YOLO5 + TransUnet, Adaptive MobileNet + IFLO	Coef. Dice 94,9% Coef. Jaccard 90,3% Acurácia 94,9%	75.222 imagens de pragas contendo 102 classes
[Vedula and Arunachalam 2026]	Detecção precoce de pragas em cultivo de arroz	CNN	Acurácia 92,8% R*ecall* 91,2% F1-score 92,0%	20.000 imagens de 4 classes de pragas de arroz e 1 classe de folhas saudáveis
[Xue et al. 2025]	Identificação de pragas em tempo real	ResNet-50 e ViT	Acurácia 97,0%	5.494 imagens com 12 classes de praga
[Barhate et al. 2025]	Detecção de pragas em tempo real utilizando *hardwares* IoT	YOLO11	mAP 85,0% Precisão 88,0% R*ecall* 82,0%	19.000 imagens com 60 pragas da agrícola indiana
[Hakim et al. 2026]	Identificação de múltiplas pragas	YOLO7-13	mAP@50 92,9% Precisão 88,0% R*ecall* 87,4%	17.251 imagens com 5 classes de insetos

3. Metodologia

A metodologia adotada neste trabalho foi estruturada em três etapas: a aquisição das imagens, o treinamento do modelo de detecção e a validação dos resultados obtidos. Inicialmente, foram obtidas e organizadas as imagens utilizadas para a identificação dos insetos-praga, tendo em vista as cinco classes de mariposas analisadas. Em seguida, os conjuntos de dados foram utilizados para o treinamento do modelo YOLO12, considerando diferentes configurações da base de dados. Por fim, o modelo treinado foi submetido à etapa de validação, na qual seu desempenho foi avaliado por meio de métricas de detecção, permitindo analisar a capacidade de identificar e classificar corretamente os insetos-praga.

3.1. Aquisição das imagens

As imagens utilizadas neste trabalho foram obtidas a partir do conjunto de dados [Workspace 2026], disponibilizado na plataforma Roboflow. A construção desse repositório reúne um acervo acumulado de imagens publicamente disponíveis na *Internet*, incluindo imagens obtidas por meio de mecanismos de busca, como o *Google Images*, além de diferentes bancos e repositórios de imagens.

O conjunto de dados possui cinco classes distintas de mariposas (Figura 1), sendo elas: *Agrotis segetum*, *Leucania loreyi*, *Spodoptera exigua*, *Spodoptera frugiperda* e *Spodoptera litura*. O conjunto disponibilizado contém 5.545 imagens originais com dimensão de 640×640 *pixels*, distribuídas entre as cinco classes, e uma versão expandida com 9.427 imagens no conjunto de treinamento, em decorrência das técnicas de aumento de dados previamente aplicadas no próprio repositório.



Figura 1. Exemplo de imagens da base de dados por espécie.

De acordo com a configuração disponibilizada, o aumento de dados aplicado ao conjunto de treinamento incluiu transformações como *Flip* vertical e horizontal, desfoque de até 3,5 pixels, aplicação de ruído de até 1,5% dos pixels e *Cutout* com quatro regiões de oclusão correspondentes a até 15% da dimensão da imagem.

3.2. Treinamento do modelo

Para a detecção das cinco espécies de insetos-praga consideradas neste trabalho, foi utilizado o modelo YOLO12 na versão nano (YOLO12n), com 2,6 milhões de parâmetros [Tian et al. 2026]. O tamanho dessa arquitetura possibilita a sua implementação no ambiente agrícola, uma vez que sistemas de monitoramento podem ser instalados diretamente em campo, incluindo regiões com infraestrutura computacional e conectividade limitadas [Upadhyay et al. 2025]. Assim, a utilização de uma arquitetura mais compacta permite reduzir o custo computacional da inferência, mantendo a capacidade de detectar pragas de forma eficiente e com potencial de futura implantação em dispositivos embarcados.

O treinamento do modelo foi realizado durante 30 épocas, utilizando o otimizador *Stochastic Gradient Descent* (SGD). A definição desse número de épocas considerou, além da necessidade de obter um aprendizado adequado das cinco espécies, a possibilidade de treinamento e atualização do modelo em campo, característica relevante para sistemas de monitoramento agrícola baseados em dispositivos embarcados. Nesse contexto, um número limitado de épocas contribui para reduzir o tempo e o custo computacional envolvidos em eventuais atualizações do modelo, tornando o processo mais compatível com cenários nos quais novos dados podem ser coletados em tempo real e utilizados posteriormente para seu aprimoramento.

Nos experimentos deste trabalho, foram consideradas duas configurações: (i) a utilização da base original, sem as imagens adicionais de aumento; e (ii) a utilização da versão expandida disponibilizada pelo Roboflow. Conforme apresentado na Tabela 2, a principal diferença entre as duas versões está no conjunto de treinamento, enquanto os conjuntos de validação e teste permaneceram inalterados. Dessa forma, as duas versões apresentam os mesmos dados para validação e teste, permitindo avaliar o impacto dessa ampliação sobre o desempenho do modelo de detecção.

As duas versões da base de dados (com e sem aumento) utilizaram a mesma configuração de treinamento e foram avaliadas considerando a capacidade do modelo de detectar corretamente as cinco classes, permitindo comparar o efeito do aumento de dados sobre o desempenho da detecção multiclasse.

Tabela 2. Distribuição das imagens por classe nos conjuntos de treino, validação e teste, considerando o treinamento com e sem aplicação de aumento de dados.

Classe	Treino (Sem aumento)	Treino (Com aumento)	Validação	Teste
Agrotis segetum	732	1460	210	104
Leucania loreyi	734	1470	208	105
Spodoptera exigua	791	1580	226	112
Spodoptera frugiperda	892	1780	254	127
Spodoptera litura	733	1474	212	105
Total	**3882**	**7764**	**1110**	**553**

3.3. Validação

Para a validação do modelo, foram utilizadas as métricas mAP@0,5, mAP@0,5:0,95, Precisão e *Recall*, que são frequentemente utilizadas na literatura para a avaliação de modelos de detecção de objetos [Tian et al. 2025]. A mAP@0,5 representa a média da precisão média (mAP) obtida considerando um limiar de interseção sobre união (IoU) com valor igual a 0,5, que é o grau mínimo de sobreposição exigido entre a caixa delimitadora prevista e a real, para que a detecção do inseto seja considerada correta. Já a mAP@0,5:0,95 é calculada a partir do mAP para diferentes limiares de IoU, variando de 0,5 a 0,95 em incrementos de 0,05, permitindo avaliar o desempenho do modelo quanto à precisão espacial das detecções. A métrica da Precisão indica a proporção de detecções corretas em relação ao total de detecções realizadas, o que indica a capacidade do modelo de evitar falsos positivos, por exemplo, ao identificar outros objetos na imagem como insetos. Por fim, o *Recall* demonstra quantos insetos foram identificados em relação ao total de insetos presentes na imagem, ou seja, a capacidade do modelo de reduzir os falsos negativos.

4. Resultados

A Tabela 3 apresenta os resultados obtidos pelo modelo YOLO12n, comparando seu desempenho antes e após a aplicação de técnicas de aumento de dados. A diversificação das amostras teve um impacto positivo no desempenho do modelo em todas as métricas avaliadas, com destaque para o *Recall*, que evoluiu de 0,9185 para 0,9686, indicando maior capacidade de detectar as mariposas presentes nas imagens e reduzir a ocorrência de falsos negativos. Também foram observados ganhos no mAP@0,5, que passou de 0,9593 para 0,9836, e no mAP@0,5:0,95, que aumentou de 0,8305 para 0,8663, evidenciando melhorias na capacidade geral de detecção.

Tabela 3. Desempenho geral do modelo YOLO12n com e sem aumento de dados.

Métricas	Base sem aumento	Base com aumento
mAP@0,5	0,9593	**0,9836**
mAP@0,5:0,95	0,8305	**0.8663**
Precisão	0,9197	**0,9456**
Recall	0,9185	**0,9686**

Os resultados apresentados na Tabela 4 demonstram que o aumento de dados contribuiu para melhorar o desempenho do YOLO12n na maioria das classes avaliadas. Nas classes *A. segetum*, *S. frugiperda* e *S. exigua* houve melhorias em todas as métricas. Para *L. loreyi*, os resultados permaneceram elevados em ambas as configurações, com *Recall* de 1,0000, indicando que todos os indivíduos dessa classe presentes no conjunto de avaliação foram identificados. Por outro lado, a classe *S. litura* apresentou uma redução de 0,87 para 0,85 na métrica mAP@0,5:0,95 após o aumento de dados, embora tenha mantido um desempenho elevado. De modo geral, os resultados indicam que o aumento de dados favoreceu a capacidade de detecção e a precisão de localização do modelo, especialmente para as classes com menor desempenho inicial.

Tabela 4. Resultados obtidos por classe com o modelo YOLO12n.

	Base sem aumento				Base com aumento			
Classe	**Precisão**	**Recall**	**mAP@0,5**	**mAP@0,5:0,95**	**Precisão**	**Recall**	**mAP@0,5**	**mAP@0,5:0,95**
Agrotis segetum	0,9218	0,8654	0,9550	0,8023	0,9513	0,9386	0,9826	0,8790
Leucania loreyi	0,9786	1,0000	0,9934	0,8874	0,9769	1,0000	0,9925	0,8895
Spodoptera exigua	0,9117	0,8571	0,9481	0,8159	0,9429	0,9821	0,9843	0,8756
Spodoptera frugiperda	0,8244	0,8898	0,9207	0,7772	0,9149	0,9306	0,9754	0,8321
Spodoptera litura	0,9626	0,9805	0,9798	0,8700	0,9537	0,9801	0,9834	0,8557

A Figura 2 apresenta exemplos dos resultados de predição obtidos pelo modelo YOLO12n com aumento de dados. De modo geral, o modelo conseguiu identificar a maioria das espécies corretamente, mesmo diante de imagens com diferentes condições de captura, variações de aparência e indivíduos com diferentes tamanhos e posições nas imagens. Assim, o modelo demonstra capacidade de generalização na detecção dos insetos. Observam-se, em particular, bons níveis de confiança nas predições de *A. segetum*, *L. loreyi*, *S. exigua* e *S. litura*. Entretanto, destaca-se o caso de *S. frugiperda*, no qual o modelo apresentou duas predições para o mesmo indivíduo, classificando-o como *S. frugiperda* e *S. litura*. Esse resultado evidencia uma dificuldade na diferenciação entre essas duas classes, provavelmente relacionada às semelhanças morfológicas entre as espécies, o que indica a necessidade de ampliar e diversificar as amostras dessas classes no conjunto de treinamento, especialmente com imagens obtidas em condições reais de campo.

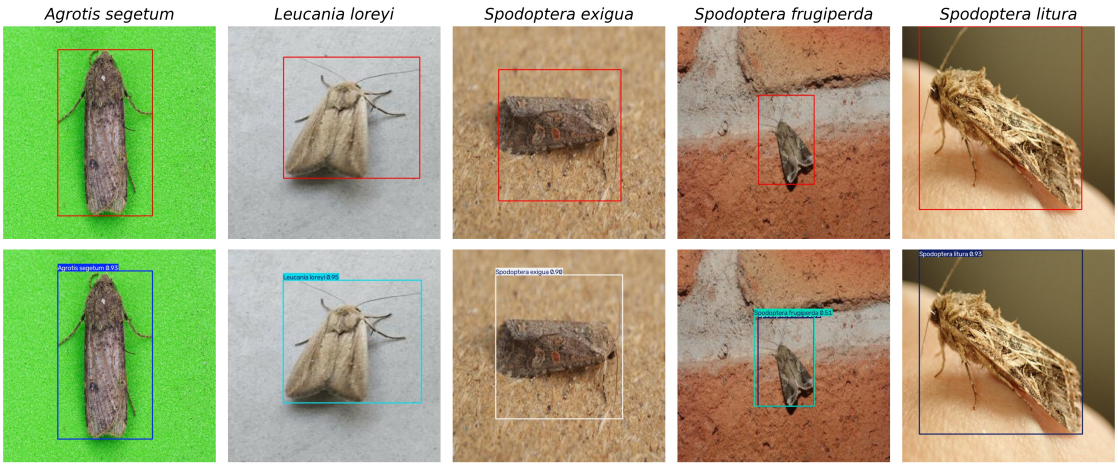


Figura 2. Comparação entre as anotações originais (linha superior) e as predições do modelo (linha inferior).

Os resultados obtidos indicam que a aplicação de técnicas de aumento de dados foi relevante para melhorar a capacidade de generalização do YOLO12n, especialmente em um cenário caracterizado pela variabilidade de tamanho, aparência e condições de captura dos insetos. A evolução das métricas demonstra que a maior diversidade das amostras contribuiu não apenas para a identificação de uma parcela maior dos indivíduos, como evidenciado pelo aumento do *Recall*, mas também para uma localização mais precisa das detecções, refletida na melhoria do mAP@0,5:0,95. Apesar do desempenho elevado, as predições apresentadas na Figura 2 evidenciam que ainda existem limitações na classificação de espécies com padrões semelhantes, como observado na confusão entre *S. frugiperda* e *S. litura*. Esse aspecto sugere que o aumento de dados, embora tenha contribuído para o desempenho geral, não elimina completamente as dificuldades de diferenciação entre classes próximas, reforçando a importância de uma base de dados mais representativa e diversificada.

Dessa forma, a utilização do modelo YOLO12n mostrou-se promissora para o monitoramento de cinco classes de insetos-praga do grupo das mariposas, especialmente por combinar um bom desempenho na detecção com uma arquitetura leve, composta por 2,6 milhões de parâmetros. O baixo custo computacional favorece sua aplicação em dispositivos embarcados, nos quais os recursos de processamento e de memória são limitados, como no *Raspberry Pi*.

5. Conclusões

A abordagem desenvolvida neste trabalho demonstrou a viabilidade do uso de técnicas de visão computacional para o monitoramento automatizado de mariposas, utilizando uma arquitetura baseada no modelo YOLO12n combinada com técnicas de aumento de dados. A solução obteve um mAP@0,5 de 0,98, sendo capaz de realizar a detecção de diferentes espécies em imagens com características variadas, contribuindo para a automatização do processo de identificação. A utilização de um modelo compacto, com 2,6 milhões de parâmetros, também reforça seu potencial para aplicações em sistemas de monitoramento com processamento em campo, nos quais a eficiência computacional é um requisito importante.

Como limitação, destaca-se a indisponibilidade de bases de dados públicas abrangentes, especialmente com imagens obtidas em condições reais de campo. Essa restrição limita a diversidade das amostras disponíveis e pode afetar a capacidade de generalização do modelo, especialmente na diferenciação entre espécies semelhantes.

5.1. Trabalhos Futuros

Como trabalhos futuros, pretende-se inicialmente avaliar outras arquiteturas de detecção de objetos, incluindo diferentes versões e modelos leves, buscando comparar desempenho, precisão, tempo de inferência e custo computacional. Essa comparação permitirá identificar a arquitetura que apresenta o melhor equilíbrio entre desempenho e eficiência para a aplicação de monitoramento de insetos-praga.

Também está prevista a ampliação da base de dados, principalmente por meio da aquisição de novas imagens em condições reais de campo, contemplando diferentes tamanhos, posições, condições de iluminação e níveis de variação entre indivíduos. Essa expansão poderá contribuir para reduzir a confusão entre espécies semelhantes, além de aumentar a capacidade de generalização dos modelos.

Por fim, pretende-se embarcar o modelo em um dispositivo com *hardware* restrito, no qual serão avaliados aspectos como o consumo de recursos computacionais, a capacidade de processamento contínuo e o desempenho em condições reais de operação, a fim de verificar a viabilidade do modelo para o monitoramento em tempo real de insetos-praga.

Referências

Arunachalam, R., Jaishankar, M., Dwivedi, U., et al. (2026). Iot-based pest detection using yolov5 with trans-unet and classification via adaptive mobilenet in agricultural fields. *International Journal of Computational Intelligence Systems*, 19:281.

Barhate, M. Y., Pame, V. V., Padate, G. S., Pame, V. V., Padhariya, D. T., Pagariya, A. P., and Pabale, V. S. (2025). Agrishield: Protecting crops with smart pest control technology developed using yolov11. In *2025 2nd International Conference on Integration of Computational Intelligent System (ICICIS)*, pages 1–5.

Embrapa (2005). *Boas Práticas Agrícolas para Produção de Alimentos Seguros no Campo: Controle de Pragas*. Brasília, DF. Programa Alimentos Seguros (PAS), Setor Campo. Convênio CNI/SENAI/SEBRAE/EMBRAPA.

Embrapa (2020). A agricultura brasileira. `https://www.embrapa.br/vii-plano-diretor/a-agricultura-brasileira`. visistado em 09-09-2026.

FAO (2026). Pest and pesticide management. `https://www.fao.org/pest-and-pesticide-management/about/understanding-the-context/`. visistado em 09-09-2026.

Hakim, A., Habib Ur-Rahman, M., Hamza, A., et al. (2026). Evaluation of yolov7-v13 models for multi-class small insect pest detection using the five-pest dataset. *Scientific Reports*, 16:23059.

Lee, J., Yin, H., Jin, D., et al. (2026). Pestdetectsim: an integrated approach for crop pest diagnosis using object detection and similarity-based image retrieval. *Plant Methods*, 22:43.

Raj, P., Kumari, N., Kumari, C., Yadav, K., and Sagar, K. (2026). Smart iot-based pest detection system using computer vision. In *2026 International Conference on Intelligent Systems in Engineering, Secured Systems and Cybersecurity (ICISESSC)*, pages 377–383.

Soares, B., Silva, W., Ponciano, G., Stefanie, B., Almeida, V., Pastori, P., Magalhães, D., and Rocha, A. (2024). Embedded neural networks for identifying spodoptera frugiperda in corn plantations. pages 376–387.

Tian, Y., Xu, W., Yang, B., Yang, X., Guo, H., Wang, G., and Yu, H. (2025). Development and evolution of yolo in object detection: A survey. *Neurocomputing*, page 132436.

Tian, Y., Ye, Q., and Doermann, D. (2026). Yolov12: Attention-centric real-time object detectors. *Advances in neural information processing systems*, 38:78433–78457.

Upadhyay, A., Sunil, G., Das, S., Mettler, J., Howatt, K., and Sun, X. (2025). Multiclass weed and crop detection using optimized yolo models on edge devices. *Journal of Agriculture and Food Research*, 22:102144.

Vedula, K. B. and Arunachalam, R. (2026). Iot-enabled pest detection using convolutional neural network for early identification. In *2026 8th International Conference on Inventive Material Science and Applications (ICIMA)*, pages 1337–1342.

Workspace (2026). moths dataset. `https://universe.roboflow.com/workspace-twcmf/moths-yzx56`. visistado em 09-09-2026.

Xue, X., Thakur, V., Dhumras, H., Jhaveri, R. H., and Gadekallu, T. R. (2025). Real-time pest detection using resnet-50 and vision transformer: An iot-enabled mobile application for smart agriculture. *IEEE Transactions on Consumer Electronics*, 71(3):8989–8997.

Zhao, C., Hu, X., and Zhu, L. (2026). A lightweight improved yolov8n model for tiny pest detection in complex cotton field environments. In *2026 7th International Conference on Artificial Intelligence and Electromechanical Automation (AIEA)*, pages 711–714.